Московский Государственный Университет имени М.В.Ломоносова
Факультет Вычислительной Математики и Кибернетики

Отчет о практической работе по МФК "Математическая статистика и анализ данных.".

Николай Некрасов
506, ВМК МГУ

Москва, 2023

Содержание

1 Задание 1.

Цель:
Выяснить:
- В каких колонках есть пропущенные значения
- Количество строк, в которых есть пропущенные значения
- Особенность, присущую рейсам, в которых есть пропущенные значения
Сделать:
- Удалить строки, в которых есть хотя бы одно пропущенное значение
Исследование: Для решения поставленной задачи используется библиотека pandas для языка программирования Python.
Столбцы, в которых содержатся NaN: dep_time, dep_delay, arr_time, arr_delay, tailnum, air_time.
Общее количество строк, в которых содержатся NaN: 9430.
Общей особенностью всех рейсов с NaN является тот факт, что в каждом таком рейсе отсутствует значение air_time.

2 Задание 2.

Цель:
Построить:
- Нормированные гистограммы задержек вылета и прилета в одних осях
Описать:
- Характер выбросов
Исследование: Для построения гистограмм будет использоваться библиотека matplotlib для языка программирования Python. Нахождение выбросов будет осуществляться с помощью межквартильного диапозона. На рис. 1 приведена гистограмма задержек вылетов и прилетов с исключёнными выбросами.

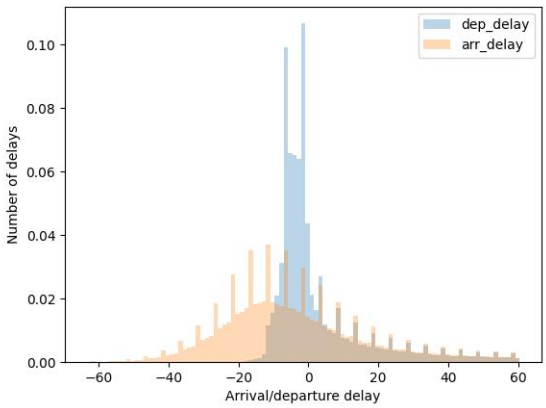

Рис. 1

На рисунках 2, 3 приведены гистограммы задержек отправления для значений меньше и больше нижней границы соответственно. На рисунках 2, 3 приведены гистограммы задержек прибытия для значений меньше и больше нижней границы соответственно.

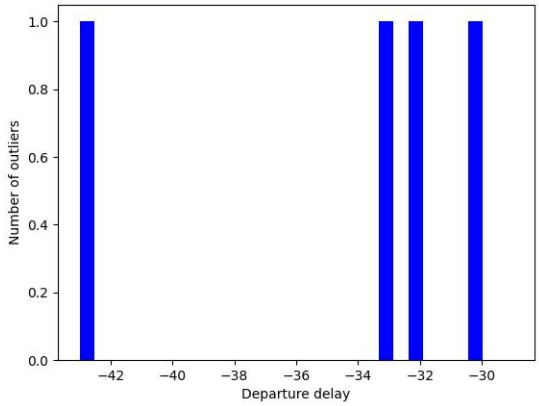

Рис. 2

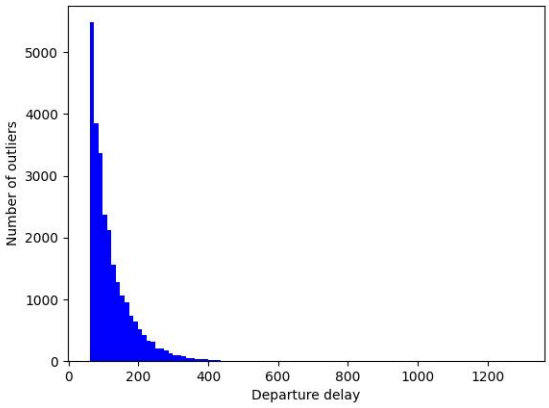

Рис. 3

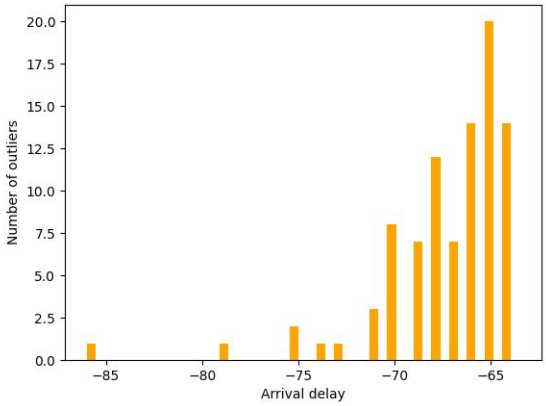

Рис. 4

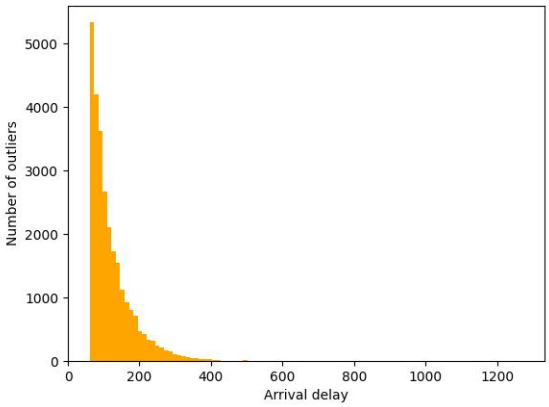

Рис. 5

Характеристика выбросов для задержек отправления, меньших нижней границы:

-30.0	1
-32.0	1
-43.0	1
-33.0	1

Характеристика выбросов для задержек отправления, больших верхней границы приведена в файле highAnomDepFile.txt по причине его большого размера.
Характеристика выбросов для задержек прибытия, меньших нижней границы:

-65.0	20
-64.0	14
-66.0	14
-68.0	12
-70.0	8
-67.0	7
-69.0	7
-71.0	3
-75.0	2
-73.0	1
-74.0	1
-86.0	1
-79.0	1

Характеристика выбросов для задержек прибытия, больших верхней границы приведена в файле highAnomArrFile.txt по причине его большого размера. Наиболее заметной особенностью распределения задержек прибытия является резкий скачкообразный рост частоты задержек через одинаковые интервалы.

3 Задание 3.

Цель:
Вычислить:
- Среднее значение
- Медиану
- Стандартное отклонение
для задержек прибытий и отправлений.
Исследование: Для решения поставленной задачи будет использоваться метод describe() библиотеки matplotlib.
Результат:
Для задержек отправления:
- Среднее значение = 12.555155706805643
- Медиану = -2
- Стандартное отклонение = 40.06568758558352
Для задержек прибытия:
- Среднее значение = 6.89537675731489
- Медиану = -5
- Стандартное отклонение = 44.63329169019399

4 Задание 4.

Цель:
Построить:
- 95%-доверительный интервал по каждой авиакомпании
- Графики доверительных интервалов для каждой компании
Отсортировать:
- Авиакомпании по средней задержке вылета
Исследование: Для построения графиков будет использоваться библиотека matplotlib. Доверительные интервалы будут построены с помощью формулы $\overline{X} = z_{\alpha/2}\frac{s}{\sqrt{n}}$, где $z_{\alpha/2} = 1.95$, $s-$стандартное отклонение, n - величина выборки.
Запишем компании в порядке возрастания средней задержки отправления:
US = 3.74469265291715
HA = 4.900584795321637
AS = 5.830747531734838
AA = 8.569130121764172
DL = 9.223949809056192
MQ = 10.445380836362183
UA = 12.016908379772248
OO = 12.586206896551724
VX = 12.756645817044566
B6 = 12.967547965734797
9E = 16.439574418873597
WN = 17.66165725672534

FL = 18.605984251968504
YV = 18.89889705882353
EV = 19.838929326132895
F9 = 20.201174743024964
На рис.5 построены графики этих интервалов:

Рис.5

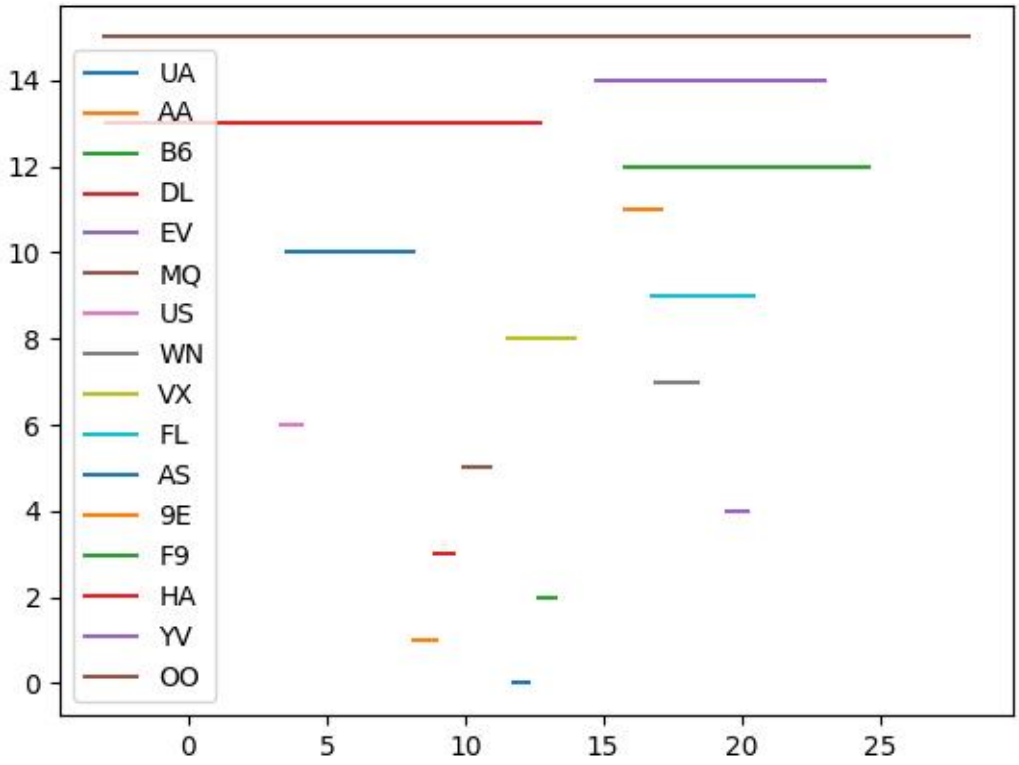

5 Задание 5.

Цель:
Выяснить:
- Является ли различие в среднем времени задержек вылетов для авиакомпаний AL и DL статистически значимым
Исследование: Для выяснения статистической значимости будет использован T-тест, в данном случае он применим, т.к. средние значения из соответствующих выборок распределены нормально. T-тест реализован функцией ttest_ind() из библиотеки scipy.
Результаты: $p - value = 0.018$, тогда опровергнуть гипотезу о равенстве средних можно на уровне значимости 1.8%. Отсюда следует заключить, что различия статистически значимы.

6 Задание 6.

Цель:
Выяснить:
- Является ли различие в среднем времени задержек вылетов для аэропортов EWR, JFK и LGA статистически значимым
Исследование: Для выяснения статистической значимости будет использован T-тест, в данном случае он применим, т.к. средние значения из соответствующих выборок распределены нормально. T-тест реализован функцией ttest_ind() из библиотеки scipy.
Результаты: Для аэропортов JFK и LGA $p - value = 4.96 * 10^{-24}$.
Для аэропортов JFK и EWR $p - value = 3.98 * 10^{-70}$.
Для аэропортов LGA и EWR $p - value = 1.9 * 10^{-161}$.
Откуда следует, что различия статистически значимы.

7 Задание 7.

Цель:
Выяснить:
- Каким распределением описывается распределение положительных времён задержек.
- Оценить:
- Параметры данного распределения.
Исследование: Т.к. по смыслу данное распределение является дискретным, то попробуем подобрать наиболее подходящее распределение методом конечных моментов среди трёх распределений: геометрического, пуассона и биномиального. Для решения этой задачи применим функцию logpmf из библиотеки scipy.
Результат:
В результате работы функции, мы получили следующие значения для $p - value$:
Геометрическое: -594880.3176988165
Пуассона: -594880.3176988165
Биномиальное: -598015.7138514676
Откуда следует, что геометрическое распределение подходит наилучшим образом. Т.к. данное распределение является дискретным, то понятие плотности для него не определено. Гистограмма приведена на рис.6. Значение параметра
$p = 0.025485840988861405$.

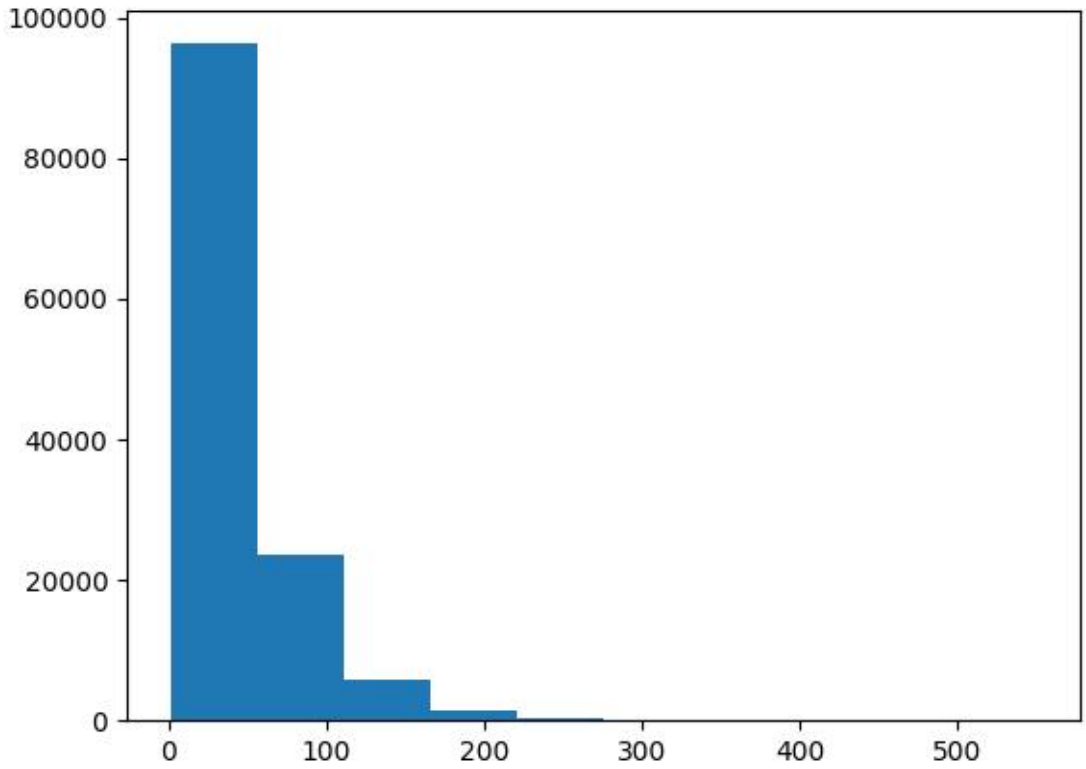

Рис. 6

8 Задание 8.

Цель:
Построить:
- Графики числа рейсов в месяц и среднего времени задержки в месяц в одних осях для тех рейсов, где величина задержки отправления положительна
- Линию регрессии на графике из предыдущего пункта
Выписать:
- Уравнение регрессии **Исследование:** Уравнение регрессии имеет вид : $y = a + bx$, где $b-$ коэффициент корреляции, a вычисляется через b и математические ожидания данных случайных величин. Для вычисления этих коэффициентов воспользуемся функцией corr из библиотеки numpy.
Результаты: Указанный график изображен на рис. 6.

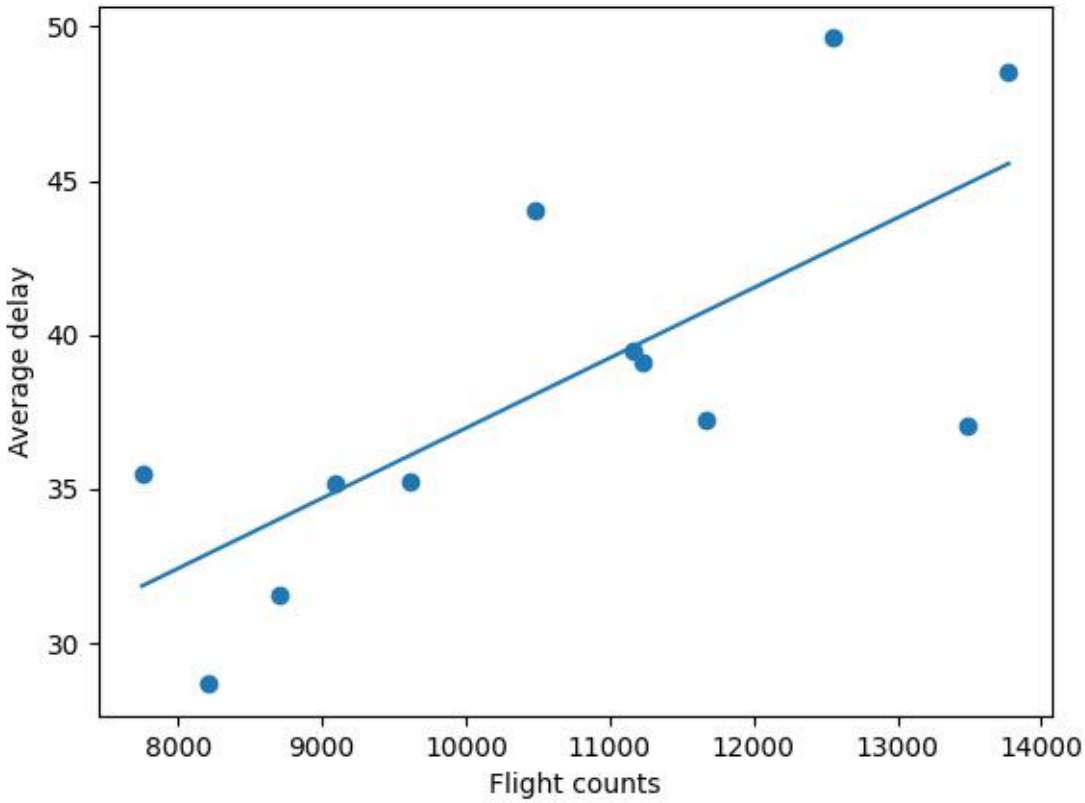

Рис. 6

Уравнение регрессии имеет вид: $y = 4.167570987425143 * 10^{-14}x + 12.519599580514178$

9 Задание 9.

Цель:
Построить:
- График среднего времени задержки в зависимости от часа вылета
- График доли рейсов, для которых задержка положительна, в зависимости от часа
Результат:
График среднего времени задержки в зависимости от часа вылета представлен на рис. 7.

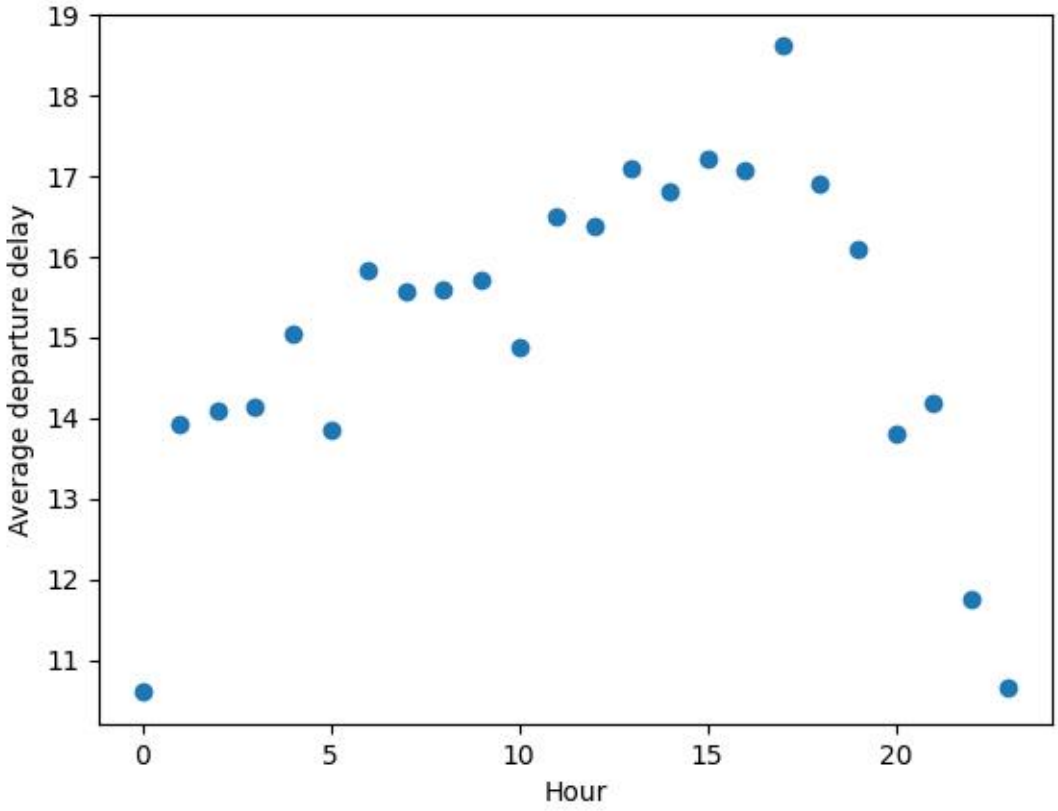

Рис. 7

График доли рейсов, для которых задержка положительна, в зависимости от часа представлен на рис. 8.

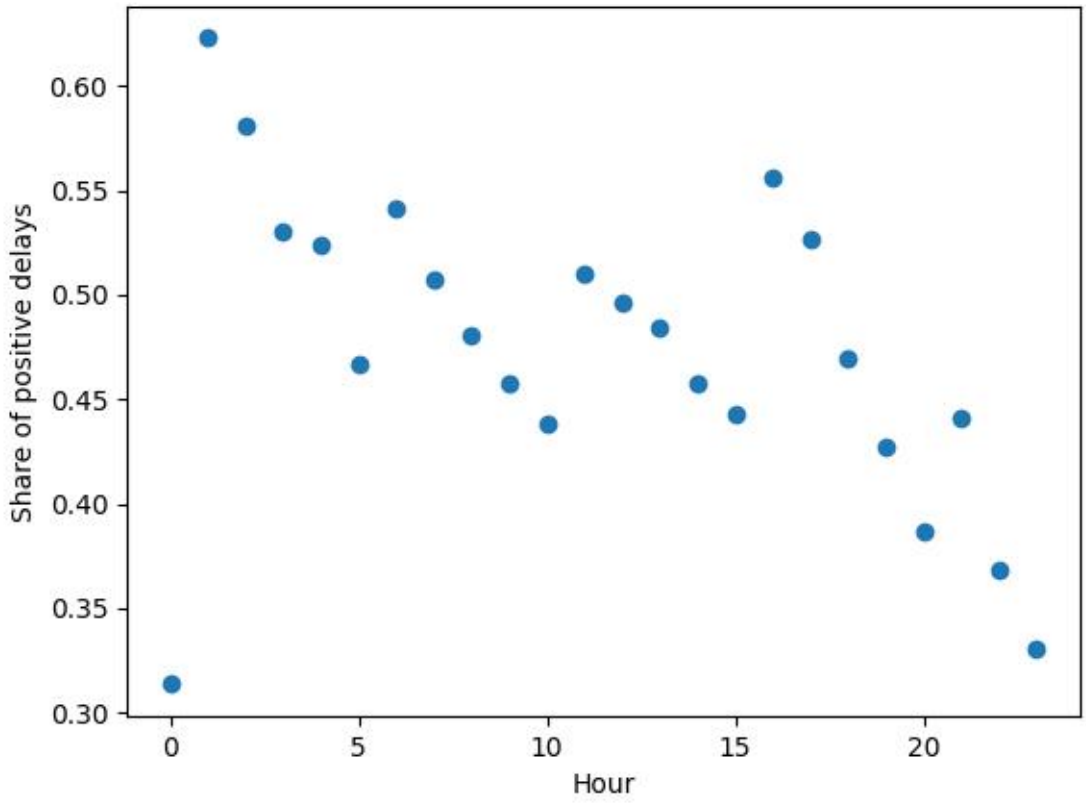

Рис. 8

Можно заметить, что наибольшая доля положительных задержек происходит в ночное, медленно снижаясь к концу дня. На графике есть два резких скачка, возможно, их можно объяснить тем, что работа в аэропортах происходит в две смены. К концу каждой из смен персонал устает, что приводит к большему числу ошибок, что, в свою очередь, увеличивает частоту задержек отправлений.

10 Задание 10.

Цель:
- Выяснить:
- Какие компании являются пунктуальными
- Зависит ли предложенное разделение независимым от дальности перелета

Исследование:
Для решения данной задачи применим алгоритм кластеризации на 2 кластера по методу квадратичной ошибки.

Результат:
В результате применения алгоритма получены следующие кластеры:

Первый кластер:
AA
DL
MQ
US
AS
HA
Второй кластер:
UA
B6
EV
WN
VX
FL
9E
F9
YV
OO
Если отфильтровать входные данные, взяв дистанции меньше или больше среднего значения, то мы получим точно такие же кластеры. Поэтому пунктуальность компании не зависит от дальности полёта.

11 Задание 12.

Цель:
- Выяснить:
- Является ли различие в задержках прибытия и отправления у борта с номером 'N14228' и другими бортами статистически значимым.
Исследование: Для ответа на данный вопрос применим T-тест. Он применим, т.к. средние значения в этих выборках распределены нормально.
Результат:
Сравнение данного с борта с другими бортами показывает, что различия статистически значимы, т.е. величины задержек прибытия и отправления зависит от номера борта. Аналогичный результат можно получить для других бортов. Значения $p - value$ содержатся в файлах tailnumsDep.txt и tailnumsArr.txt.